

# APLICACION DE MACHINE LEARNING EN AJEDREZ

Por: Jesús González Suárez

# CONTENIDOS

1

Introducción

2

Metodología

3

Resultados

4

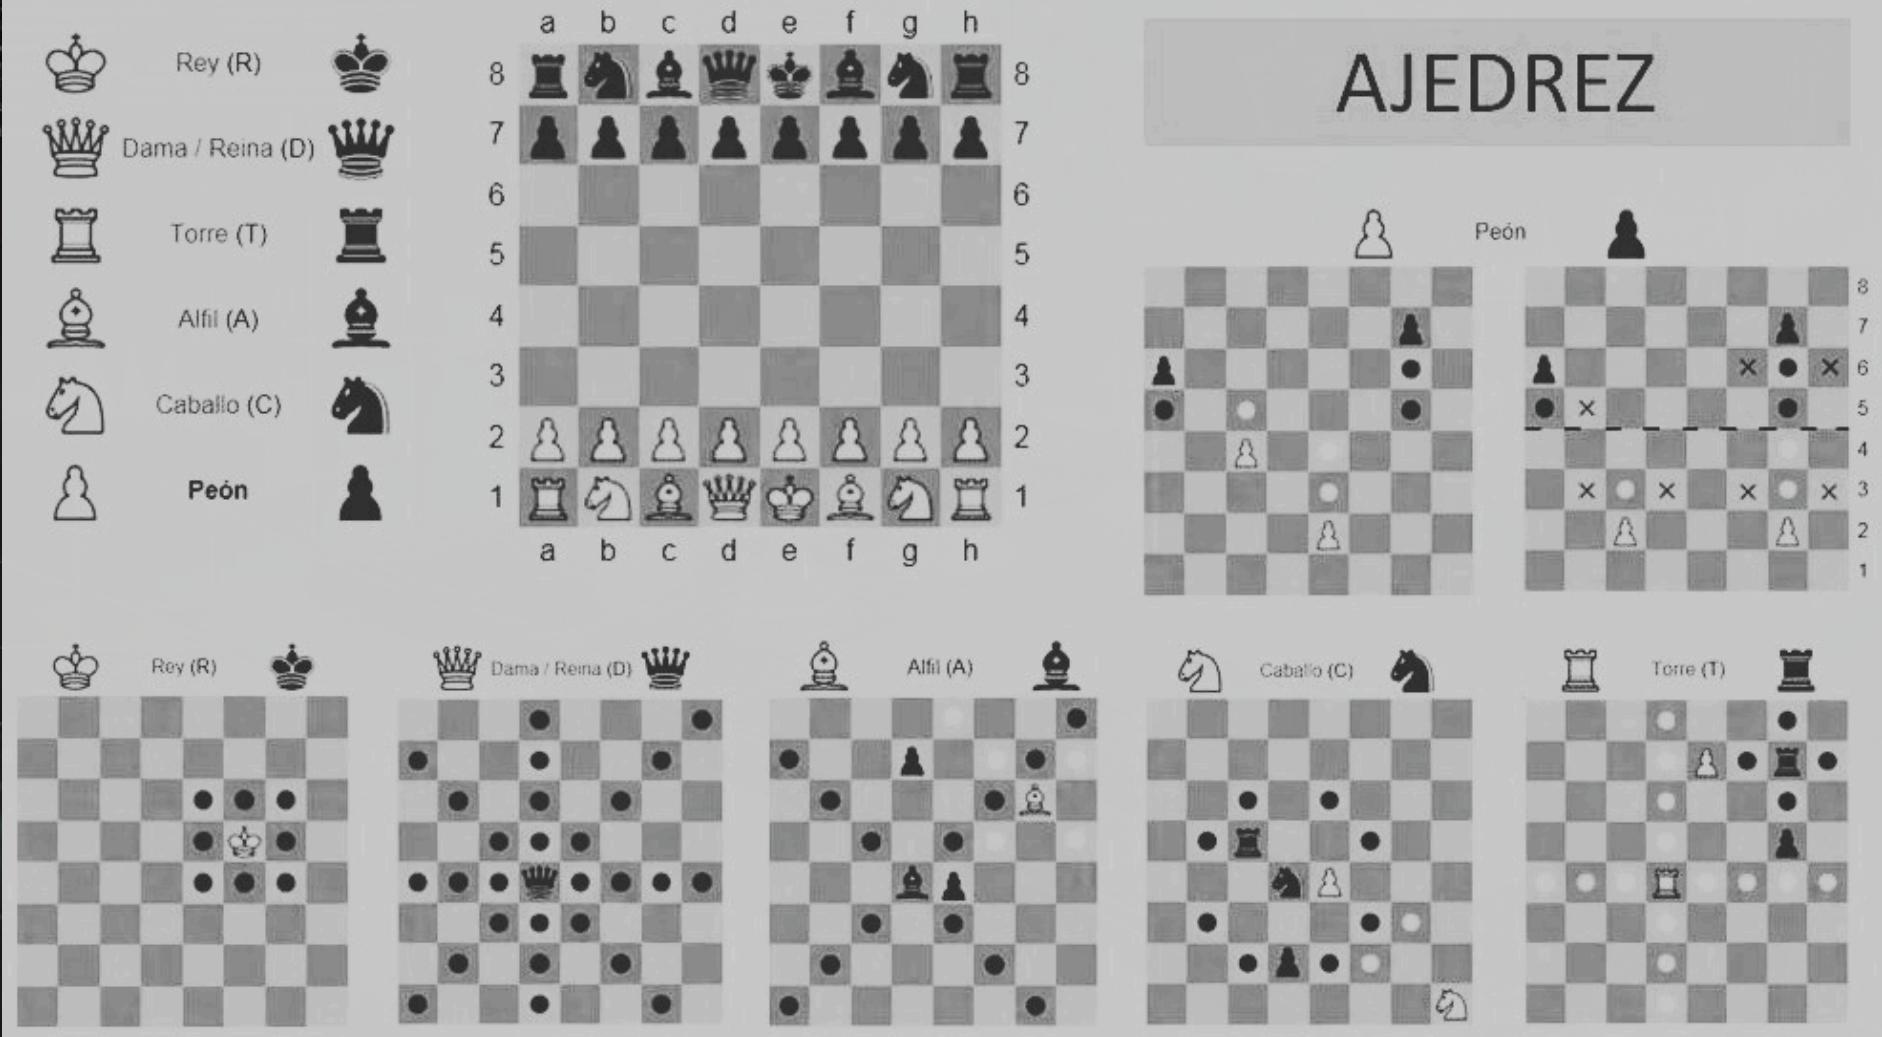
Conclusion

5

Preguntas



# INTRODUCCIÓN



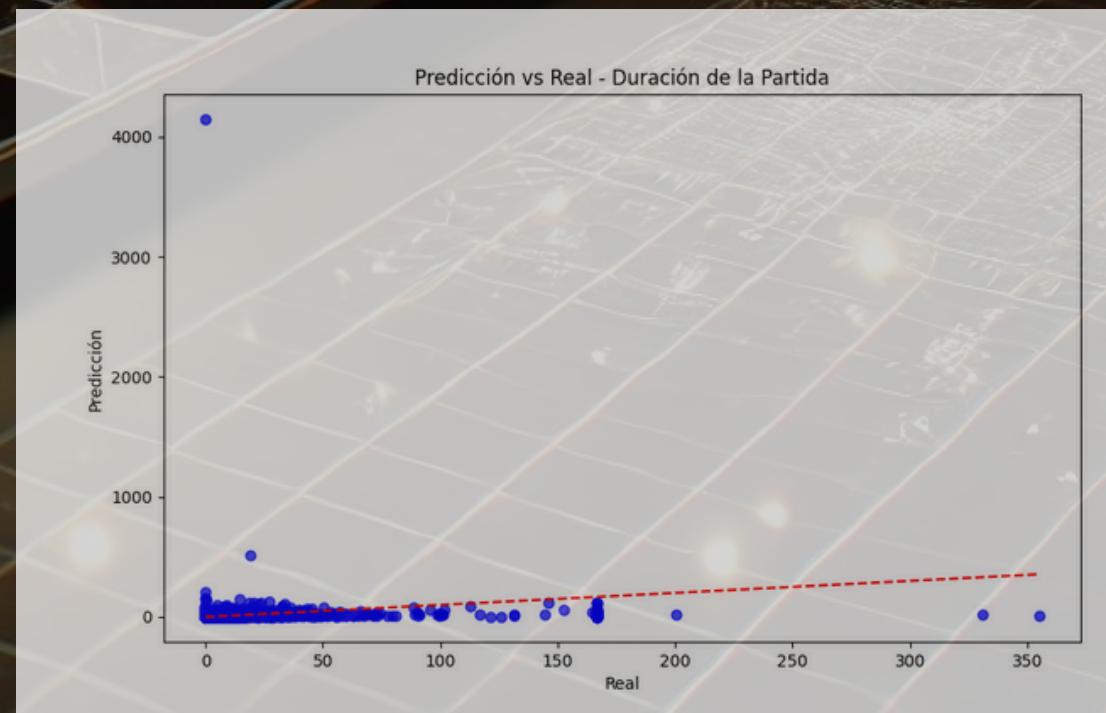
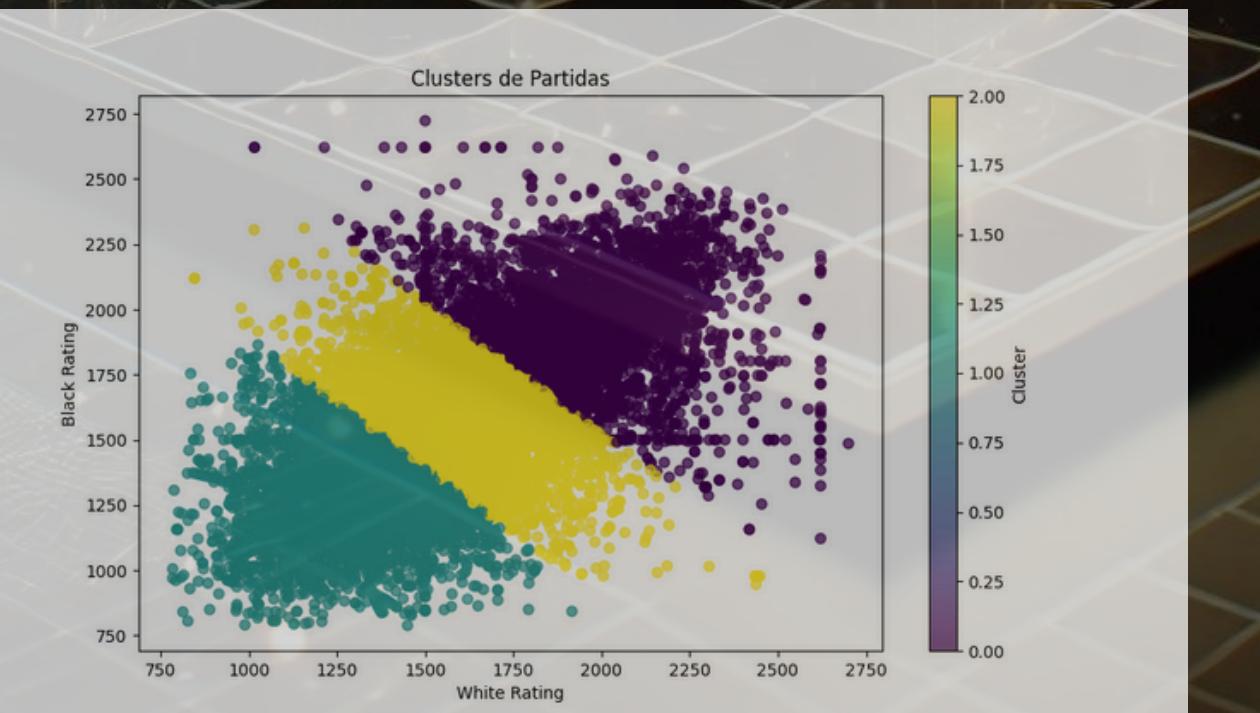
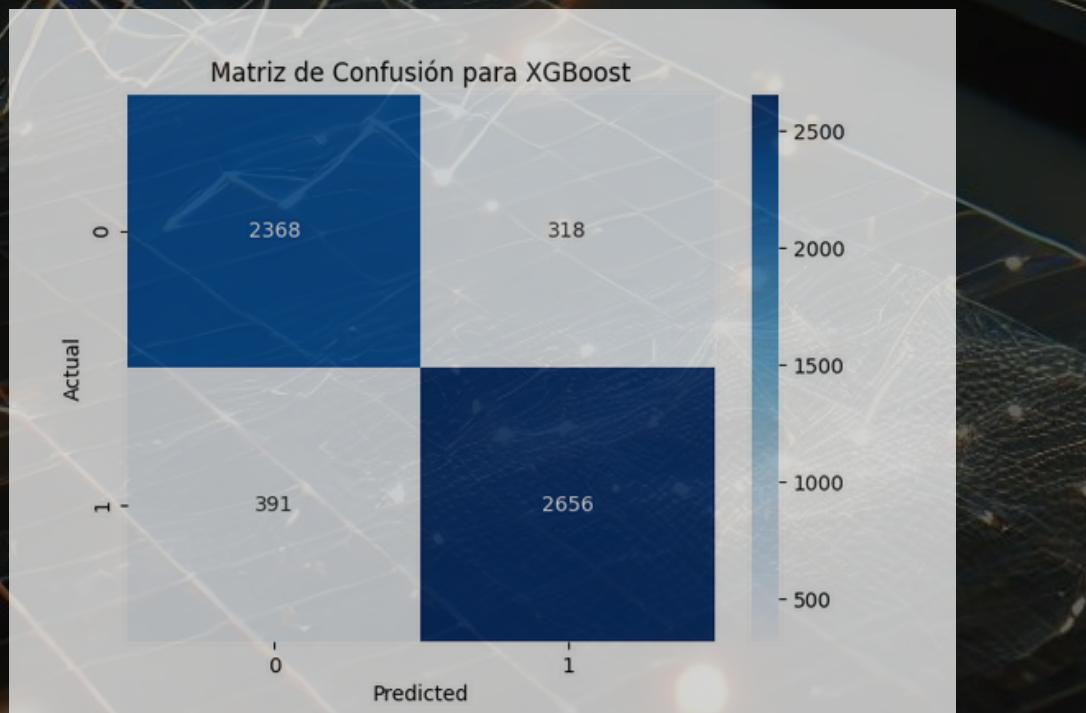
## • Objetivo del Proyecto

- Explorar el uso de técnicas de Machine Learning para analizar ajedrez.
- Mejorar la experiencia del juego mediante sugerencias de movimientos, predicción de resultados y análisis de patrones.

# METODOLOGIA

## • Datos Utilizados

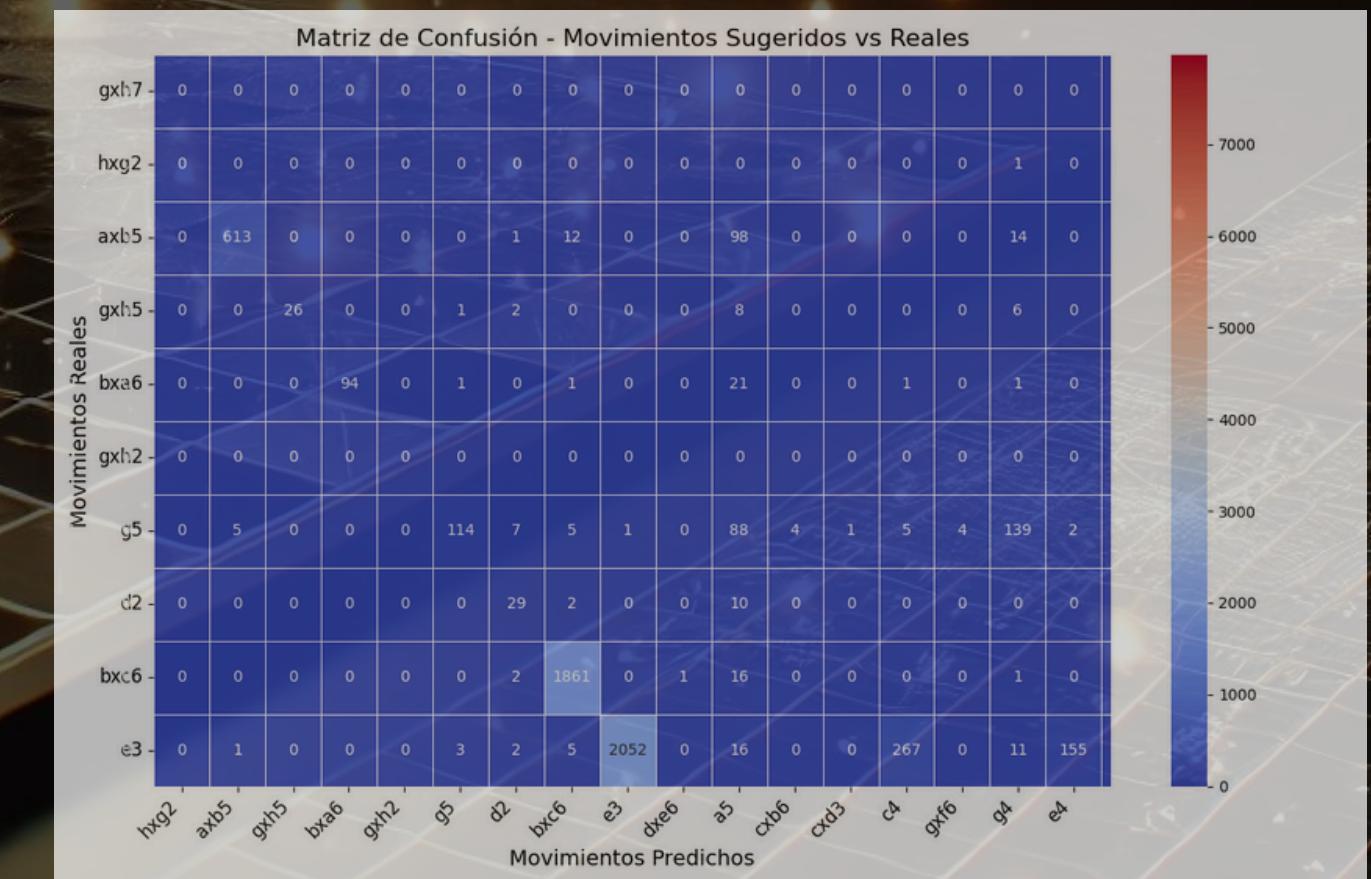
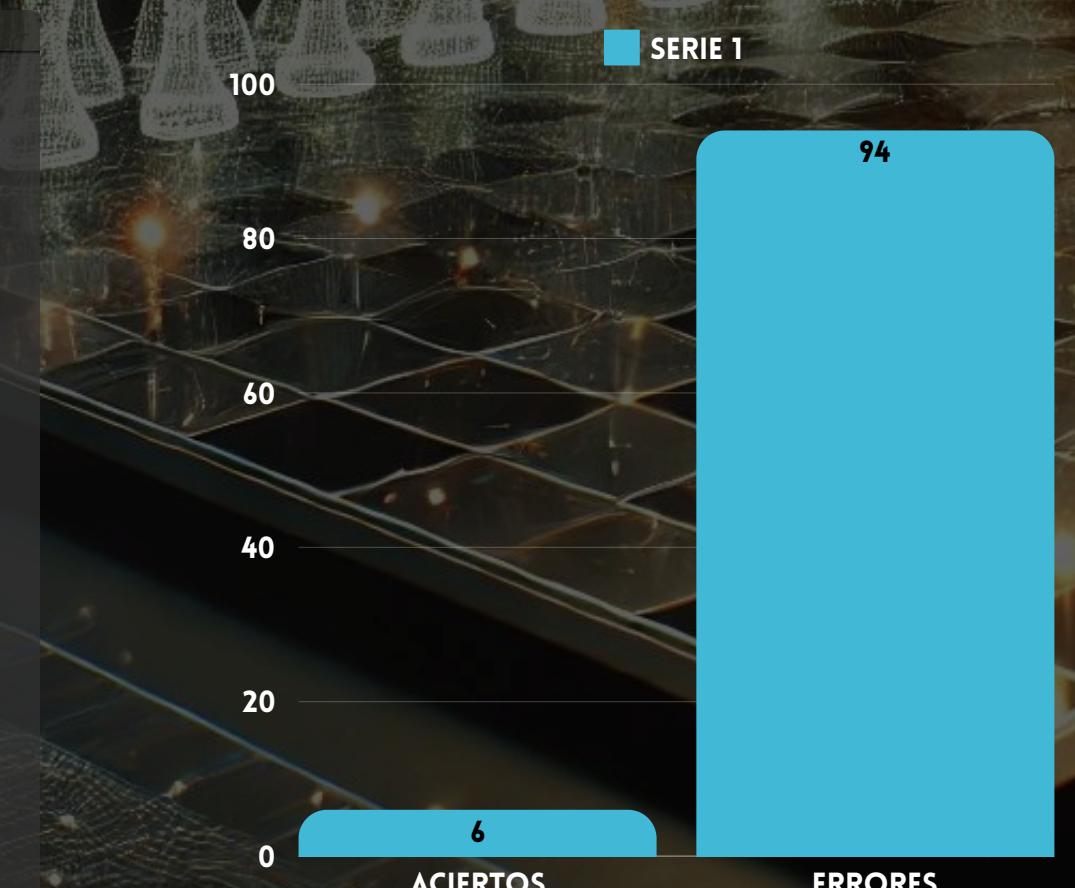
- Origen: Dataset en formato PGN
- Features :
  - Número de Turnos
  - Duración Partida
  - Rating Jugadores
  - Apertura utilizada
- Visualizacion



# METODOLOGIA

- Modelos Implementados

- Modulo de Movimientos:
  - Modelo basado en una red neuronal con TensorFlow, entrenada en GoogleColab
  - Entrada: secuencia de movimientos previos.
  - Salida: predicción del siguiente movimiento.

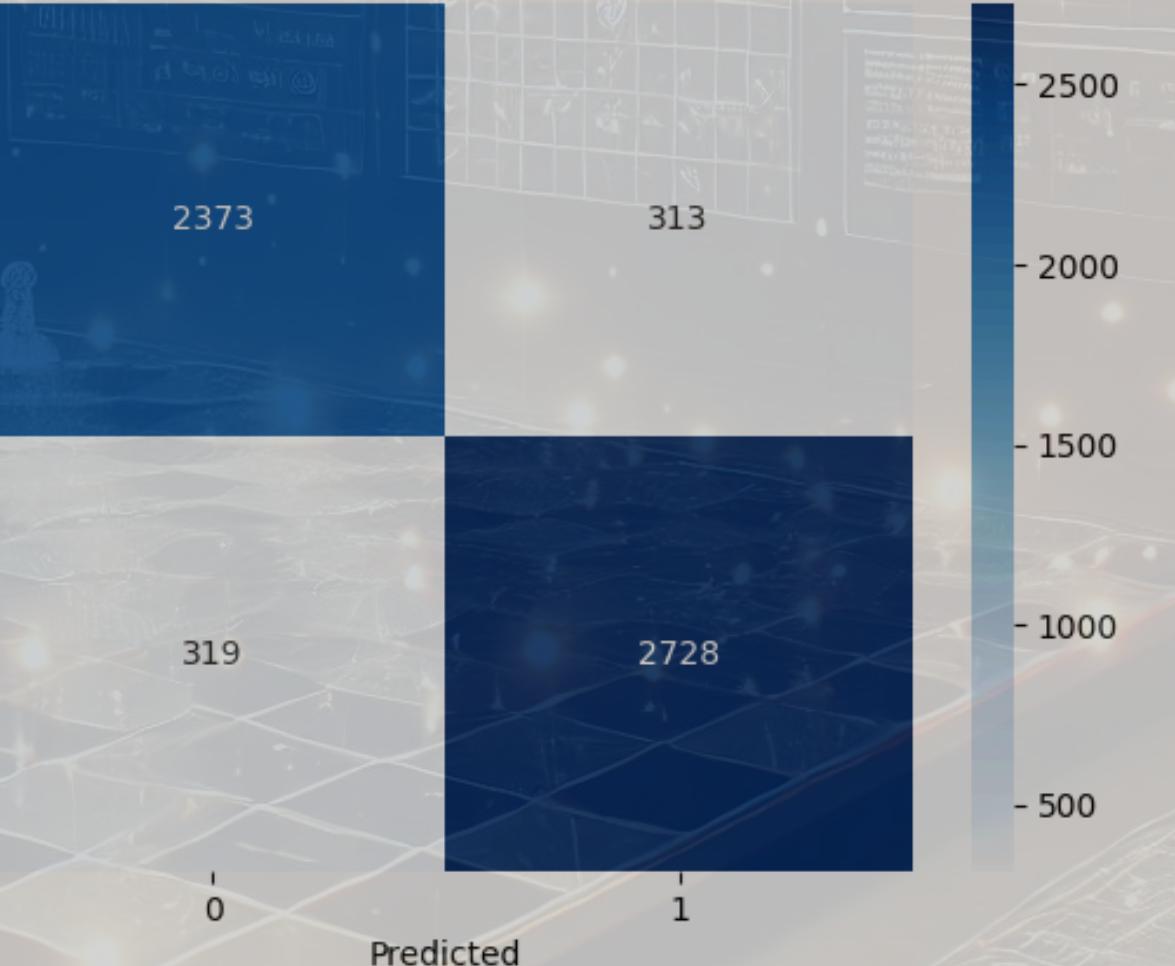


# METODOLOGIA

- **Modelos Implementados**

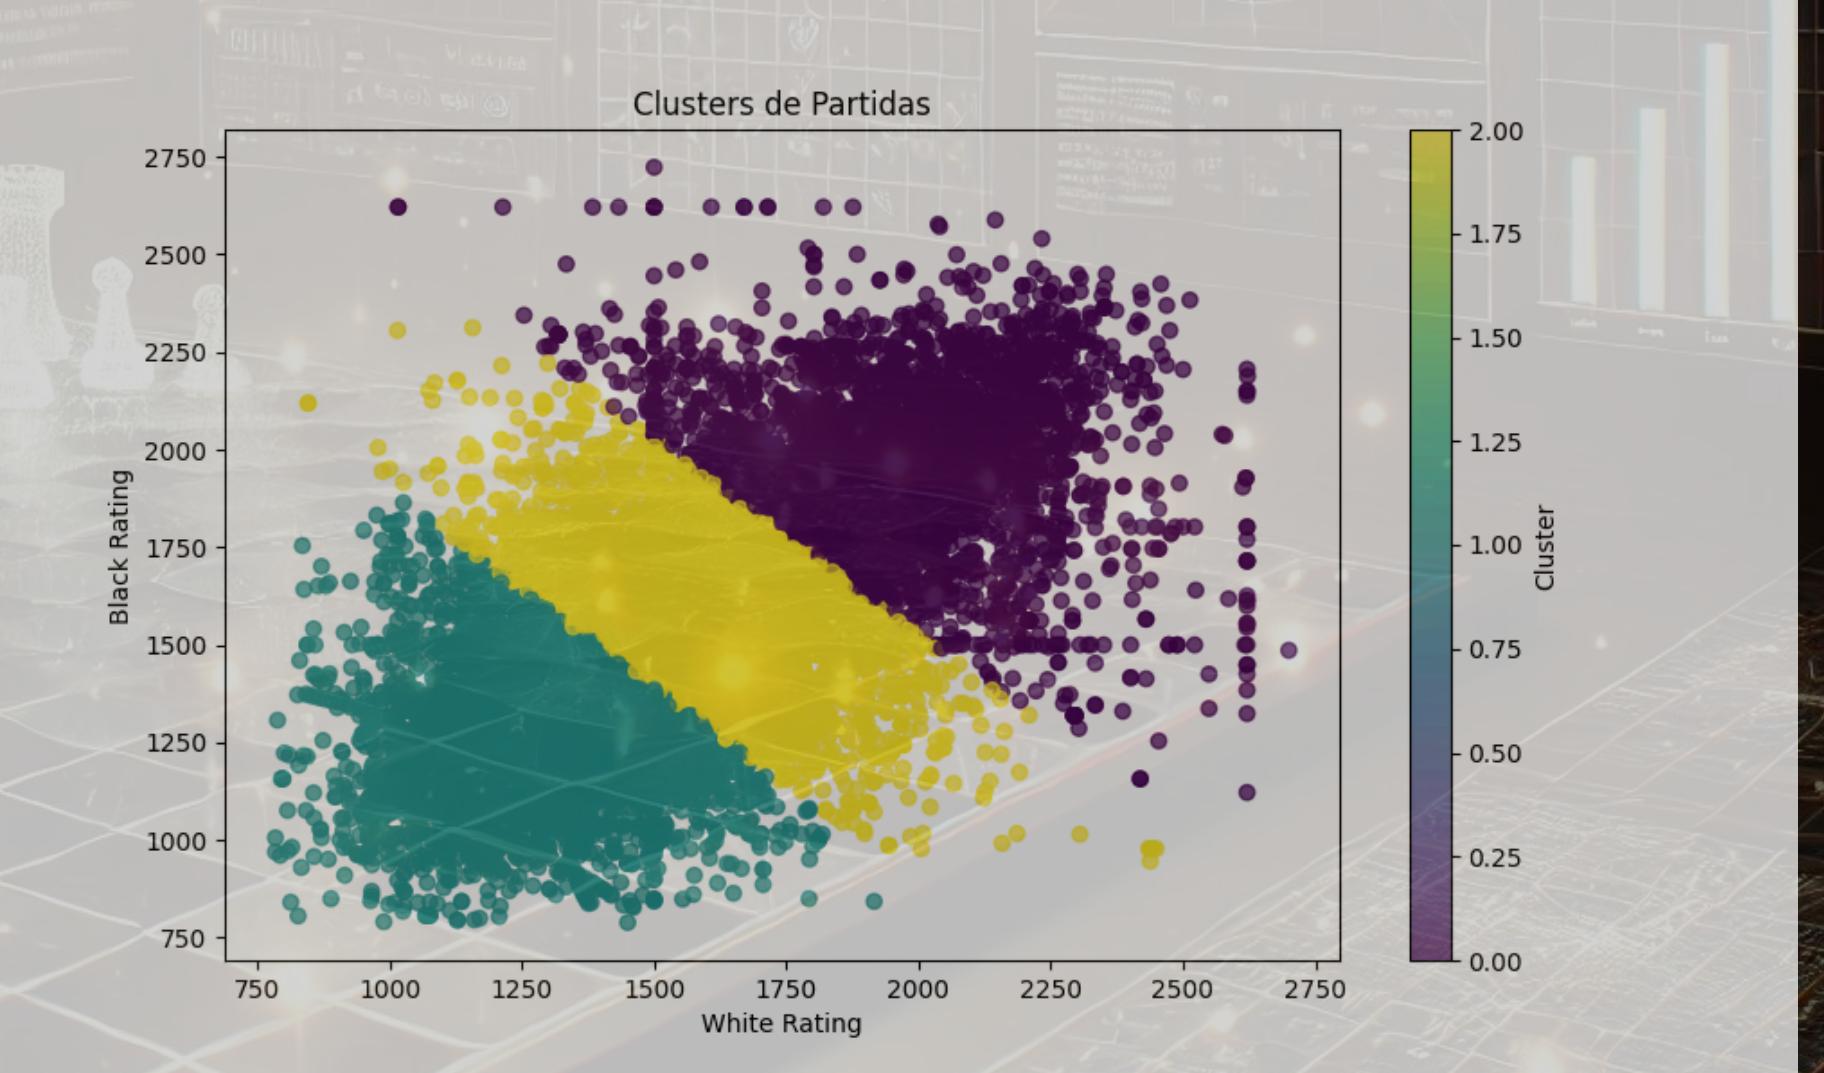
- Predicción del Ganador:
  - GradientBoostingClassifier
- Características utilizadas
  - Número de turnos
  - puntuación de jugadores
  - ventaja de puntuación
  - duración
  - apertura.
- Resultados:
  - Precisión promedio: 84%

Matriz de Confusión para GradientBoosting



# METODOLOGIA

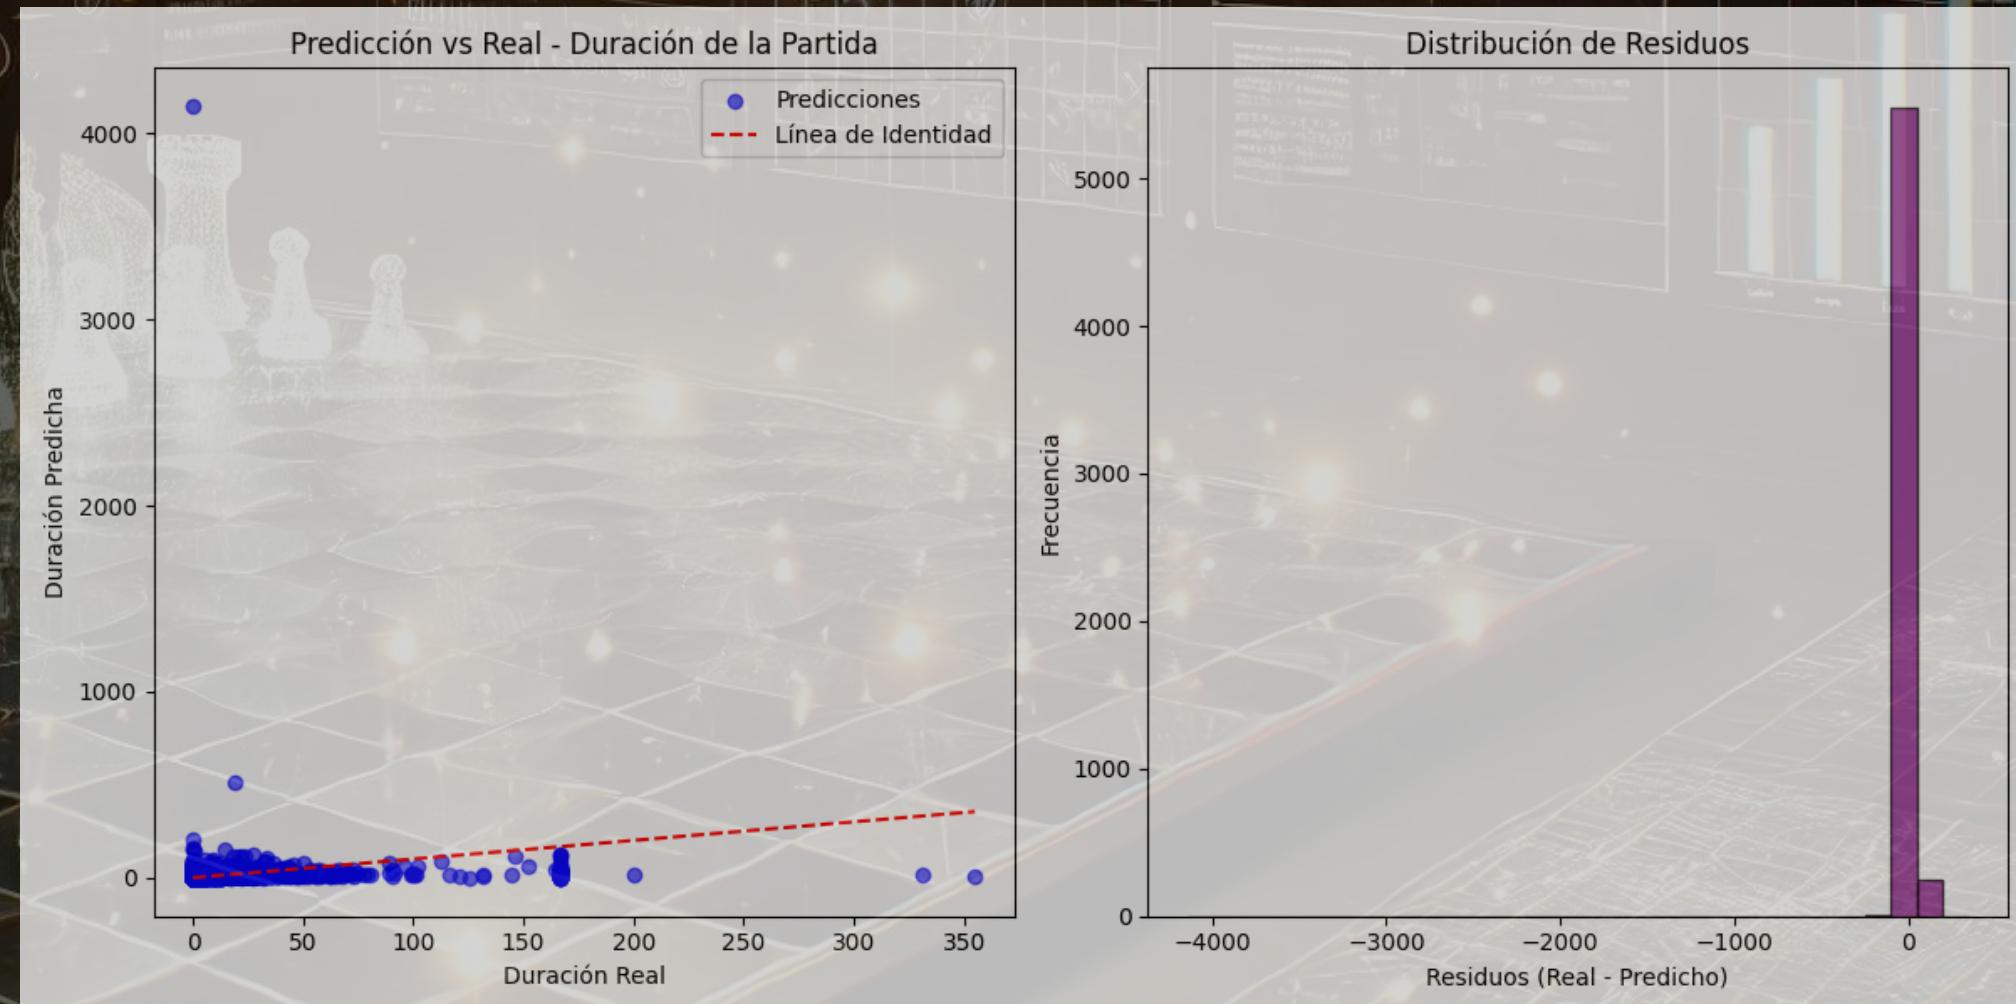
- Modelos Implementados
  - Clustering:
    - Kmeans
  - Características utilizadas
    - Puntuación de jugadores (blanco y negro)
    - Duración de la partida.
  - Resultados:
    - Identificación de 3 clusters principales:
      - Cluster 1: Partidas rápidas con alta puntuación.
      - Cluster 2: Partidas de media duración y puntuación equilibrada.
      - Cluster 3: Partidas largas con una clara ventaja inicial.



# METODOLOGIA

## • Modelos Implementados

- Predicción de la Duracion Partida:
  - RandomForestRegressor
- Caracteristicas utilizadas
  - Número de turnos.
  - Puntuación de los jugadores
  - Ventaja de puntuación
  - Apertura
- Resultados:
  - MAE (Error Absoluto Medio): 17,76
  - RMSE (Raíz del Error Cuadrático Medio): 65.01
- Importancia: Ayuda a entender los factores que determinan la duración de una partida.



# CONCLUSIONES

- El modelo muestra un rendimiento aceptable tanto en la predicción de la duración de la partida como en la predicción del Ganador, están razonablemente cerca de los valores reales, aunque existen errores grandes en algunos casos.
  - La discrepancia entre MAE y RMSE sugiere que el modelo tiene dificultades con algunos valores extremos (outliers), lo que afecta negativamente el rendimiento global.
- Importancia de las Variables:
  - El análisis de las características utilizadas en el modelo sugiere que algunas variables son más relevantes que otras para predecir la duración de las partidas.
  - Una selección más cuidadosa de las características podría mejorar el rendimiento del modelo, eliminando ruido innecesario.
- El análisis segmentado reveló que ciertos factores, como el estilo de juego (agresivo vs. defensivo), correlacionan con tiempos más predecibles y mayores probabilidades de victoria.
  - Recomendación: Profundizar en los factores dentro de cada clúster para optimizar estrategias adaptadas al perfil del jugador o equipo.
- El modelo y la interfaz proponen una solución efectiva para predecir la duración de partidas y analizar el desempeño por clústeres.
- Aunque el modelo logra un buen desempeño inicial, la precisión podría mejorarse mediante ajustes en datos y parámetros, especialmente para manejar mejor los outliers.
- La segmentación por clústeres ha permitido identificar patrones clave que pueden ser útiles para personalizar estrategias y mejorar la experiencia del jugador.
- La interfaz provee un puente intuitivo entre los análisis complejos y la interpretación fácil para los usuarios finales, lo que aumenta su valor práctico.



**¿PREGUNTAS?  
MUCHAS GRACIAS**